



UNIVERSIDAD NACIONAL DE INGENIERIA
FACULTAD DE INGENIERÍA
ECONÓMICA, ESTADÍSTICA
Y CIENCIAS SOCIALES

Patrones de Accidentes de Tránsito en las Carreteras del Perú: Análisis por Departamento y Consecuencias (2020–2021)

INTEGRANTES:

- Randy Olortegui
- Audrey Asenjo
- Rosa Davila
- Sayuri Uceda

RESUMEN



El presente proyecto analiza los accidentes de tránsito ocurridos en carreteras del Perú durante los años 2020 y 2021 utilizando información oficial de la Superintendencia de Transporte Terrestre de Personas, Carga y Mercancías (SUTRAN). El objetivo es identificar patrones relacionados con la distribución geográfica de los accidentes, su modalidad y las consecuencias en términos de fallecidos y heridos. Para ello se realizó una exploración inicial de los datos mediante Python, incluyendo revisión de calidad, detección de duplicados y análisis descriptivo. Los resultados preliminares muestran una alta concentración de accidentes en determinados departamentos y diferencias importantes entre modalidades de siniestro.

INTRODUCCIÓN

- Los accidentes de tránsito representan uno de los principales problemas de seguridad vial en el Perú. Su impacto se refleja en pérdidas humanas, daños materiales y costos económicos para la sociedad. El análisis de datos oficiales permite identificar patrones que contribuyan a comprender mejor la distribución y características de estos eventos.
- Este trabajo utiliza información proporcionada por SUTRAN con el propósito de realizar una exploración inicial de los accidentes registrados en carreteras peruanas durante los años 2020 y 2021.



OBJETIVOS

GENERALES

Analizar los accidentes de tránsito ocurridos en carreteras del Perú durante los años 2020 y 2021 para identificar patrones geográficos y características relevantes de los siniestros.

ESPECÍFICOS

- Identificar los departamentos con mayor cantidad de accidentes.
- Analizar las modalidades de accidente más frecuentes.
- Examinar la distribución de fallecidos y heridos.
- Comparar el comportamiento de los accidentes entre departamentos.



PREGUNTAS DE ANÁLISIS

¿Qué departamentos registran la mayor cantidad de accidentes?

¿Cuáles son las modalidades de accidente más frecuentes?

¿Qué departamentos concentran más fallecidos?

¿Existen diferencias importantes entre departamentos respecto a la gravedad de los accidentes?



FUENTE OFICIAL DOCUMENTADA



SUTRAN — Superintendencia de Transporte Terrestre de Personas, Carga y Mercancías
<https://www.datosabiertos.gob.pe/dataset/accidentes-de-tr%C3%A1nsito-en-carreteras-sutran>

FECHA DE CONSULTA
2025

PERIODO DE COBERTURA
Ene 2020 – Dic 2021

FORMATO DE DESCARGA
CSV (sep. punto y coma)

DESCRIPCION DEL DATA SET

DIMENSIONES DEL DATA SET

8155

100K

29

Registros(Filas)

Variables(columnas)

*Departamentos
cubiertos*

UNIDAD DE ANÁLISIS:

Cada fila del dataset representa un evento de accidente de tránsito individual registrado por SUTRAN en una carretera peruana. La unidad mínima es el siniestro vial único, identificado por su fecha, hora, vía y kilómetro.

Diccionario básico de variables

TÍTULO	DESCRIPCIÓN	TIPO DE DATO	TAMAÑO	RECURSO RELACIONADO	INFORMACIÓN ADICIONAL
FECHA_CORTE	Fecha de corte de la información	Numérico	8		
FECHA	Fecha del accidente de tránsito	Numérico	8		
HORA	Hora del accidente de tránsito	Numérico	5		"N.I." significa "no identificado". En 88 accidentes de tránsito no se registró la hora.
DEPARTAMENTO	Departamento donde se localizó el accidente de tránsito	Texto	13		"N.I." significa "no identificado". En 7 accidentes de tránsito no se registró el departamento.
CODIGO_VIA	Código de la vía en la que se reportó el accidente de tránsito	Alfanumérico	6		"N.I." significa "no identificado". En 46 accidentes de tránsito no se registró el código de vía.
KILOMETRO	Kilómetro de la vía en la que se reportó el accidente de tránsito	Numérico	4		"N.I." significa "no identificado". En 45 accidentes de tránsito no se registró el kilómetro.
MODALIDAD	Modalidad del accidente de tránsito: atropello, choque, despiste, especial, volcadura o N.I. "N.I." significa "no identificado"	Texto	9		"N.I." significa "no identificado". En 28 accidentes de tránsito no se registró la modalidad.
NUM_FALLECIDOS	Número de personas reportadas como fallecidas	Numérico	2		"N.I." significa "no identificado". En 3 accidentes de tránsito no se registró la cantidad de fallecidos.
NUM_HERIDOS	Número de personas reportadas como heridas	Numérico	2		"N.I." significa "no identificado". En 10 accidentes de tránsito no se registró la cantidad de heridos.

Carga y limpieza de Datos

1. Carga de Datos

El dataset original de la Sutran presentaba dos problemas:

- Primero, venía codificado en un estándar de Windows que altera los caracteres en español (como tildes o la 'Ñ'), por lo que forzamos la lectura con `encoding='latin-1'` para no perder información textual.
- Segundo, al haber sido exportado en formato regional, las columnas no estaban divididas por comas, sino por puntos y comas. Especificamos `sep=';'` para que Pandas distribuyera los datos correctamente en una estructura matricial limpia, evitando que toda la información colapsara en una sola columna."

```
ruta_dataset = '/content/drive/MyDrive/DAS_ENTREGABLE1/Accidentes de tránsito en carreteras-2020-2021-Sutran.csv'

# Añadimos sep=';' para separar las columnas y encoding='latin-1' para las tildes
df_raw = pd.read_csv(ruta_dataset, sep=';', encoding='latin-1')

df_raw.head()
```

Dataset de Siniestralidad Vial – SUTRAN

	FECHA_CORTE	FECHA	HORA	DEPARTAMENTO	CODIGO_VÍA	KILOMETRO	MODALIDAD	FALLECIDOS	HERIDOS
0	20211222	20200101	05:40	LIMA	PE-1S	24	DESPISTE	0	0
1	20211222	20200101	16:30	CAJAMARCA	PE-3N	74	DESPISTE	0	0
2	20211222	20200101	07:45	PASCO	PE-3N	103	DESPISTE	0	1
3	20211222	20200101	18:30	CAJAMARCA	PE-08	111	DESPISTE	0	2
4	20211222	20200101	18:40	LIMA	PE-1N	174	DESPISTE	0	5
5	20211222	20200101	16:30	ICA	PE-1S	199	CHOQUE	0	1
6	20211222	20200101	16:35	ICA	PE-1S	201	CHOQUE	1	1
7	20211222	20200101	21:45	HUANUCO	PE-3N	226	ATROPELLO	0	1
8	20211222	20200101	23:50	PIURA	PE-1N	232	CHOQUE	0	6
9	20211222	20200101	02:30	AMAZONAS	PE-5N	263	DESPISTE	0	2
10	20211222	20200101	23:40	AREQUIPA	PE-1S	521	CHOQUE	0	0
11	20211222	20200101	17:45	LA LIBERTAD	PE-1N	732	DESPISTE	0	5
12	20211222	20200101	10:30	LA LIBERTAD	PE-1N	734	DESPISTE	0	2
13	20211222	20200101	20:50	MOQUEGUA	PE-1S	1166	CHOQUE	0	0
14	20211222	20200101	16:50	TACNA	PE-1S	1245	DESPISTE	1	0
15	20211222	20200101	18:15	PUNO	PE-1S	1351	CHOQUE	0	0
16	20211222	20200102	12:50	AREQUIPA	PE-1SJ	6	DESPISTE	2	16
17	20211222	20200102	05:45	TACNA	PE-1SD	8	DESPISTE	2	1
18	20211222	20200102	16:30	AREQUIPA	PE-34J	14	CHOQUE	0	0
19	20211222	20200102	16:30	AREQUIPA	PE-34E	18	CHOQUE	0	3
20	20211222	20200102	11:00	AREQUIPA	PE-34A	34	ESPECIAL	0	0
21	20211222	20200102	10:10	LIMA	PE-1N	39	ATROPELLO	1	0
22	20211222	20200102	08:00	CAJAMARCA	PE-3N	43	CHOQUE	0	0
23	20211222	20200102	00:40	LIMA	PE-22	81	CHOQUE	0	1
24	20211222	20200102	08:25	LIMA	PE-1S	81	DESPISTE	0	0
25	20211222	20200102	11:20	LIMA	PE-1S	91	DESPISTE	0	1

```
print(f"El dataset tiene",df_raw.shape[0],"filas y",df_raw.shape[1],"columnas")
```

El dataset tiene 8155 filas y 9 columnas

Tratamiento de Datos

1. Tratamiento de Datos Faltantes


En el dataset existían datos 'N.I.' que eran los datos no identificados o no registrados en los accidentes este tipo de dato textual se remplazaron por valores nulos reales.

```
for col in ['MODALIDAD', 'FALLECIDOS', 'HERIDOS']:
    ni_count = (df_raw[col].astype(str).str.strip() == 'N.I.').sum()
    print(f" '{col}' → valores 'N.I.': {ni_count}")
```

```
'MODALIDAD' → valores 'N.I.': 28
'FALLECIDOS' → valores 'N.I.': 3
'HERIDOS' → valores 'N.I.': 10
```

```
df_raw = df_raw.replace(['N.I.', 'N.I', 'N. I.'], np.nan)

print("CONTEO REAL DE VALORES FALTANTES (N.I. TRANSFORMAOS A NULL): ")
print(df_raw.isnull().sum())
```



```
'MODALIDAD' → valores 'N.I.': 0
'FALLECIDOS' → valores 'N.I.': 0
'HERIDOS' → valores 'N.I.': 0
```

1. Correccion de Tipos y Creacion de variables Derivadas

- Las variables 'FALLECIDOS' y 'HERIDOS' contenían caracteres de texto debido a los 'N.I.'
- Las casteamos a tipo numérico entero para poder realizar sumas y promedios.
- Con respecto a la variable temporal, la 'FECHA' original venía almacenada como un número plano de 8 dígitos (AAAAMMDD). La transformamos a un formato cronológico real
- Derivamos tres variables de alto valor analítico: el Año, el Mes y el Día de la Semana en español.


```
df_raw = df_raw.replace(['N.I.', 'N.I', 'N. I.'], np.nan)

print("CONTEO REAL DE VALORES FALTANTES (N.I. TRANSFORMAOS A NULL): ")
print(df_raw.isnull().sum())
```

```
print("Tipos de datos:")
df_raw.dtypes
```


Tipos de datos:

	0
FECHA_CORTE	int64
FECHA	int64
HORA	object
DEPARTAMENTO	object
CODIGO_VÍA	object
KILOMETRO	object
MODALIDAD	object
FALLECIDOS	object
HERIDOS	object



	0
FECHA	datetime64[ns]
HORA	object
DEPARTAMENTO	object
CODIGO_VÍA	object
KILOMETRO	object
MODALIDAD	object
FALLECIDOS	float64
HERIDOS	float64
AÑO	int32
MES	int32
HORA_NUM	float64
CON_VICTIMAS	int64


Nulos y Duplicados



1. NULOS

Identificamos los datos nulos, pero no lo vamos a eliminar porque al eliminarlos estaríamos perdiendo información de las filas que tienen 'N.I.'

```
CONTEO REAL DE VALORES FALTANTES (N.I. TRANSFORMAOS A NULL):  
  
FECHA_CORTE      0  
FECHA            0  
HORA             88  
DEPARTAMENTO      7  
CODIGO_VÍA       46  
KILOMETRO        45  
MODALIDAD        28  
FALLECIDOS       3  
HERIDOS          10  
dtype: int64
```



1. DUPLICADOS

El criterio que se usa para los datos duplicados es que tenemos que borrar las fila donde las variables Fecha, Hora, Código de la Vía y Kilómetro sean iguales, ya que es imposible que ocurran dos accidentes distintos en el mismo kilometro, fecha y hora de una carretera. Por ende este tipo de factores delata la duplicidad de registro.

```
columnas_evento = ['FECHA_LIMPIA', 'HORA', 'CODIGO_VÍA', 'KILOMETRO']  
  
# Aplicamos el filtro manteniendo el primer registro  
df_procesado = df_raw.drop_duplicates(subset=columnas_evento, keep='first')  
filas_final, col_final = df_procesado.shape
```

Duplicados eliminados: 35 filas removidas (8,120 filas restantes)

NULOS: FALLECIDOS 3 , HERIDOS 10

Dataset de Siniestralidad Vial – SUTRAN (Limpia)

	FECHA	HORA	DEPARTAMENTO	CODIGO_VÍA	KILOMETRO	MODALIDAD	FALLECIDOS	HERIDOS	AÑO	MES	HORA_NUM	CON_VICTIMAS	
0	2020-01-01	05:40	LIMA	PE-1S	24	DESPISTE	0.0	0.0	2020	1	5.0	0	
1	2020-01-01	16:30	CAJAMARCA	PE-3N	74	DESPISTE	0.0	0.0	2020	1	16.0	0	
2	2020-01-01	07:45	PASCO	PE-3N	103	DESPISTE	0.0	1.0	2020	1	7.0	1	
3	2020-01-01	18:30	CAJAMARCA	PE-08	111	DESPISTE	0.0	2.0	2020	1	18.0	1	
4	2020-01-01	18:40	LIMA	PE-1N	174	DESPISTE	0.0	5.0	2020	1	18.0	1	
5	2020-01-01	16:30	ICA	PE-1S	199	CHOQUE	0.0	1.0	2020	1	16.0	1	
6	2020-01-01	16:35	ICA	PE-1S	201	CHOQUE	1.0	1.0	2020	1	16.0	1	
7	2020-01-01	21:45	HUANUCO	PE-3N	226	ATROPELLO	0.0	1.0	2020	1	21.0	1	
8	2020-01-01	23:50	PIURA	PE-1N	232	CHOQUE	0.0	6.0	2020	1	23.0	1	
9	2020-01-01	02:30	AMAZONAS	PE-5N	263	DESPISTE	0.0	2.0	2020	1	2.0	1	
10	2020-01-01	23:40	AREQUIPA	PE-1S	521	CHOQUE	0.0	0.0	2020	1	23.0	0	
11	2020-01-01	17:45	LA LIBERTAD	PE-1N	732	DESPISTE	0.0	5.0	2020	1	17.0	1	
12	2020-01-01	10:30	LA LIBERTAD	PE-1N	734	DESPISTE	0.0	2.0	2020	1	10.0	1	
13	2020-01-01	20:50	MOQUEGUA	PE-1S	1166	CHOQUE	0.0	0.0	2020	1	20.0	0	
14	2020-01-01	16:50	TACNA	PE-1S	1245	DESPISTE	1.0	0.0	2020	1	16.0	1	
15	2020-01-01	18:15	PUNO	PE-1S	1351	CHOQUE	0.0	0.0	2020	1	18.0	0	
16	2020-01-02	12:50	AREQUIPA	PE-1SJ	6	DESPISTE	2.0	16.0	2020	1	12.0	1	
17	2020-01-02	05:45	TACNA	PE-1SD	8	DESPISTE	2.0	1.0	2020	1	5.0	1	
18	2020-01-02	16:30	AREQUIPA	PE-34J	14	CHOQUE	0.0	0.0	2020	1	16.0	0	
19	2020-01-02	16:30	AREQUIPA	PE-34E	18	CHOQUE	0.0	3.0	2020	1	16.0	1	
20	2020-01-02	11:00	AREQUIPA	PE-34A	34	ESPECIAL	0.0	0.0	2020	1	11.0	0	
21	2020-01-02	10:10	LIMA	PE-1N	39	ATROPELLO	1.0	0.0	2020	1	10.0	1	
22	2020-01-02	08:00	CAJAMARCA	PE-3N	43	CHOQUE	0.0	0.0	2020	1	8.0	0	
23	2020-01-02	00:40	LIMA	PE-22	81	CHOQUE	0.0	1.0	2020	1	0.0	1	

ESTADISTICAS DESCRIPTIVAS



VARIABLES NUMERICAS:

	FALLECIDOS	HERIDOS
count	8117.00	8110.00
mean	0.17	1.31
std	0.79	2.55
min	0.00	0.00
25%	0.00	0.00
50%	0.00	1.00
75%	0.00	2.00
max	33.00	71.00



ESTADISTICAS DESCRIPTIVAS

COMPARACIONES POR AÑO:

Accidentes por año

AÑO	
2020	4004
2021	4116

Fallecidos y Heridos por año

	FALLECIDOS	HERIDOS
AÑO		
2020	679.0	5290.0
2021	696.0	5353.0


ESTADÍSTICAS DE ACCIDENTES SEGÚN MODALIDAD DE TRANSPORTE/TRÁNSITO

```
mod_stats = df.groupby('MODALIDAD').agg(  
    Accidentes=('MODALIDAD', 'count'),  
    Fallecidos=('FALLECIDOS', 'sum'),  
    Heridos=('HERIDOS', 'sum')  
)  
.sort_values('Accident', ascending=False)  
mod_stats['% Accidentes'] = (mod_stats['Accident'] / len(df) * 100).round(1)  
display(mod_stats)
```

	Accidentes	Fallecidos	Heridos	% Accidentes
MODALIDAD				
DESPISTE	3809	513	4879	46.9
CHOQUE	3609	669	5281	44.4
ATROPELLO	361	160	239	4.4
ESPECIAL	186	20	88	2.3
VOLCADURA	128	8	128	1.6

LOS 10 DEPARTAMENTOS CON MAYOR SINIESTRALIDAD

```
print("    Top 10 Departamentos\n")  
print(df['DEPARTAMENTO'].value_counts().head(10).to_string())
```



Top 10 Departamentos

DEPARTAMENTO	
LIMA	1553
AREQUIPA	792
JUNIN	711
ANCASH	600
PUNO	526
ICA	374
CAJAMARCA	348
CUSCO	345
LAMBAYEQUE	339
LA LIBERTAD	328



METODOLOGÍA





OBTENCIÓN DE DATOS

CARGAR DATOS EN PYTHON

REVISAR CALIDAD DE DATOS


ANÁLISIS DE DATOS

VISUALIZACIÓN



GRÁFICO


Durante 2021 se registró una mayor cantidad de accidentes en la mayoría de los meses analizados respecto a 2020. Los meses de agosto y septiembre presentan algunos de los valores más altos del periodo.




GRÁFICO

Los accidentes por despiste y choque representan más del 90% de los casos registrados en la base de datos. El despiste constituye la modalidad más frecuente con 3,809 accidentes (47.1%), seguido por los choques con 3,609 accidentes (44.6%).

Proporción por modalidad



Accidentes por modalidad



GRÁFICO

